

Prédiction de la Vitesse du Vent Horaire ELM vs MLP – Étude Comparative

Année universitaire :	2025 – 2026
Module :	Apprentissage Automatique / Réseaux de Neurones
Date de rendu :	10 mai 2026
Outils utilisés :	Python 3, NumPy, Scikit-learn, Matplotlib

1. Introduction

Ce travail pratique a pour objectif de construire et comparer deux modèles de régression pour la prédiction de la vitesse du vent horaire. Le fichier de données *windSpeedData.txt* contient 52 559 mesures successives de vitesse du vent (en m/s). L'approche adoptée consiste à utiliser une fenêtre glissante de **10 valeurs passées** (instants t à $t+9$) pour prédire la valeur future à l'instant $t+10$, ce qui transforme le problème en une tâche de régression supervisée.

Deux architectures de réseaux de neurones sont comparées :

- **ELM (Extreme Learning Machine)** : réseau à une couche cachée dont les poids d'entrée sont initialisés aléatoirement et figés ; seuls les poids de sortie sont calculés analytiquement par la pseudo-inverse de Moore-Penrose.
- **MLP (Multi-Layer Perceptron)** : réseau à plusieurs couches entraîné par rétropropagation avec l'optimiseur Adam, via *sklearn.neural_network.MLPRegressor*.

2. Base de Données et Préparation

2.1 Description du jeu de données

Paramètre	Valeur
Nombre total de mesures	52 559
Taille de la fenêtre (n)	10
Nombre d'échantillons construits	52 549
Taille entraînement (80 %)	42 039
Taille test (20 %)	10 510
Partition	Chronologique (shuffle=False)

2.2 Construction des fenêtres glissantes

Pour chaque indice i allant de 0 à $N-11$, on construit :

— $X[i] = [\text{data}[i], \text{data}[i+1], \dots, \text{data}[i+9]]$ (10 features)

— $y[i] = \text{data}[i+10]$ (valeur cible)

La partition train/test est effectuée chronologiquement (*shuffle=False*) pour respecter la causalité temporelle et éviter toute fuite d'information du futur.

3. Modèle ELM – Extreme Learning Machine

3.1 Principe

L'ELM est un réseau à propagation directe (feedforward) avec une seule couche cachée. Contrairement au MLP, les poids W_i entre les entrées et la couche cachée ainsi que les biais B_i sont initialisés aléatoirement et **ne sont jamais mis à jour**. Seuls les poids beta de la couche de sortie sont calculés analytiquement :

$$\text{beta} = H^+ \cdot y$$

où H est la matrice des sorties de la couche cachée et H^+ est sa pseudo-inverse de Moore-Penrose (calculée via `numpy.linalg.pinv`). La fonction d'activation utilisée est la sigmoïde : $f(x) = 1 / (1 + e^{-x})$.

3.2 Paramètres de l'ELM

Paramètre	Valeur
Nombre de neurones cachés (L)	100
Fonction d'activation	Sigmoïde
Initialisation des poids	Uniforme [-1, 1]
Calcul des poids de sortie	Pseudo-inverse (Moore-Penrose)
Temps de convergence	1.7905 s

4. Modèle MLP – Multi-Layer Perceptron

4.1 Principe

Le MLPRegressor de scikit-learn implémente un réseau de neurones à plusieurs couches entraîné par rétropropagation du gradient. L'algorithme d'optimisation utilisé est **Adam** (Adaptive Moment Estimation). Les données d'entrée et de sortie sont normalisées par un StandardScaler avant l'entraînement pour accélérer la convergence.

4.2 Paramètres du MLP

Paramètre	Valeur
Architecture (couches cachées)	(100, 50)
Fonction d'activation	ReLU
Optimiseur	Adam
Taux d'apprentissage initial	0.001
Itérations max	500
Arrêt précoce (early stopping)	Oui (10 % validation)
Nombre d'itérations réel	18
Normalisation	StandardScaler (X et y)
Temps de convergence	3.5373 s

5. Résultats et Visualisations

5.1 Courbes comparatives ELM vs MLP

Les figures ci-dessous comparent les valeurs désirées (signal réel) aux valeurs prédites par chaque modèle sur les 200 premiers échantillons de l'ensemble de test.




Figure 1 – Courbes comparatives : valeurs désirées vs prédites (ELM, MLP et superposition).

5.2 Nuages de points (désirées vs prédites)

Un nuage de points idéal serait aligné sur la diagonale $y = x$. Plus les points s'en écartent, moins le modèle est précis.




Figure 2 – Nuages de points : valeurs désirées vs valeurs prédites pour ELM et MLP.

6. Mesures d'Évaluation

Les quatre métriques standards de régression sont utilisées pour évaluer les performances des deux modèles :

Métrique	Formule	Interprétation
MAE	$\text{moyenne}(y - y_{\text{pred}})$	Erreur absolue moyenne (m/s)
MSE	$\text{moyenne}((y - y_{\text{pred}})^2)$	Erreur quadratique moyenne
RMSE	$\text{racine}(\text{MSE})$	RMSE en unités originales (m/s)
R ²	$1 - \text{SS}_{\text{res}} / \text{SS}_{\text{tot}}$	Coefficient de détermination [0, 1]

6.1 Tableau comparatif des performances

Métrique	ELM	MLP	Meilleur modèle
MAE (m/s)	1.7322	0.4186	MLP
MSE	10.2793	0.3674	MLP
RMSE (m/s)	3.2061	0.6061	MLP
R ²	-1.7604	0.9013	MLP
Temps (s)	1.7905	3.5373	ELM

6.2 Exploration des hyperparamètres du MLP

a) Influence de l'architecture (couches cachées)

Architecture	R ²	RMSE (m/s)
(50,)	0.8963	0.6213
(100,)	0.8831	0.6597
(50, 25)	0.9012	0.6065
(100, 50) *	0.9013	0.6061
(100, 50, 25)	0.8993	0.6123

(*) Architecture retenue pour le modèle final.

b) Influence de la fonction d'activation

Activation	R ²	RMSE (m/s)
ReLU *	0.9013	0.6061
Tanh	0.8988	0.6138
Logistic	0.8898	0.6405

c) Influence du taux d'apprentissage

Taux d'apprentissage	R ²	RMSE (m/s)
0.1	0.6933	1.0687
0.01	0.9007	0.6082
0.001 *	0.9013	0.6061
0.0001	0.9002	0.6095

7. Analyse et Conclusion

7.1 Analyse des résultats

L'analyse des métriques met en évidence des différences importantes entre les deux modèles :

ELM : Le modèle obtient un R^2 de -1.7604, ce qui indique qu'il explique très mal la variance du signal. Un R^2 négatif signifie que le modèle est moins précis qu'une simple prédiction par la moyenne. Cela s'explique par l'absence de normalisation des données et par la nature aléatoire des poids d'entrée non optimisés pour ce signal à haute dimensionnalité. Le RMSE de 3.2061 m/s confirme une erreur de prédiction élevée.

MLP : Le modèle obtient un R^2 de 0.9013, ce qui indique qu'il explique 90.1 % de la variance du signal. Avec un RMSE de 0.6061 m/s et une MAE de 0.4186 m/s, les prédictions sont très proches des valeurs réelles. La normalisation des données et l'optimisation par Adam ont permis une convergence rapide en seulement 18 itérations.

7.2 Limites de l'ELM observées

Bien que l'ELM soit réputé pour sa rapidité d'entraînement, plusieurs facteurs limitent ses performances sur ce problème :

1. Les poids d'entrée aléatoires ne sont pas adaptés à la structure du signal de vent. Sans normalisation préalable, les valeurs d'activation sigmoïde saturent, réduisant la capacité de représentation de la couche cachée.
2. Le calcul de la pseudo-inverse sur une matrice de grande taille ($42\,039 \times 100$) peut introduire des instabilités numériques.
3. L'ELM est plus adapté à la classification qu'à la régression de signaux continus et bruités comme les séries temporelles météorologiques.

7.3 Conclusion

Critère	ELM	MLP	Vainqueur
Précision (R^2)	-1.760	0.901	MLP
Erreur (RMSE m/s)	3.206	0.606	MLP
Erreur (MAE m/s)	1.732	0.419	MLP
Temps entraînement	1.79 s	3.54 s	ELM
Complexité impl.	Faible	Moyenne	ELM
Besoin de normalisation	Non requis	Requis	ELM

Au vu des résultats obtenus, le **MLP (MLPRegressor)** est clairement le meilleur modèle de prédiction pour ce problème de série temporelle. Il obtient un R^2 de **0.9013** et un RMSE de **0.6061 m/s**, contre un R^2 de -1.7604 pour l'ELM. Bien que l'ELM soit plus rapide à entraîner (1.79 s vs 3.54 s) et plus simple à implémenter, ses performances en régression sur des données temporelles non normalisées restent insuffisantes. Le MLP, grâce à sa capacité d'optimisation itérative par rétropropagation et à la normalisation des données, produit des prédictions de haute qualité et suit fidèlement le signal réel de vitesse du vent.